

Dane są próbki dwóch klas A i B. Pierwsza klasa składa się z czterech próbek:

$$x_1^A = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad x_2^A = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \quad x_3^A = \begin{bmatrix} 0 \\ 3 \end{bmatrix} \quad x_4^A = \begin{bmatrix} 3 \\ 0 \end{bmatrix}$$

O klasie B wiadomo, że wektor średni próbek tej klasy i jej macierz kowariancji to:

$$\underline{\mu}^B = \begin{bmatrix} -2 \\ -2 \end{bmatrix} \quad C^B = \begin{bmatrix} 3 & 1 \\ 1 & 1 \end{bmatrix}$$

Która jednowymiarowa przestrzeń cech będzie lepsza z punktu widzenia możliwości poprawnej klasyfikacji próbek? Jaki będzie wynik klasyfikacji próbki $\underline{x} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ w tej przestrzeni?

$$\underline{x}^A = \begin{bmatrix} 1 & 2 & 0 & 3 \\ 1 & 2 & 3 & 0 \end{bmatrix}$$

$$\underline{\mu}^A = \frac{1}{4} * \begin{bmatrix} 1+2+0+3 \\ 1+2+3+0 \end{bmatrix} = \begin{bmatrix} \frac{1+2+0+3}{4} \\ \frac{1+2+3+0}{4} \end{bmatrix} = \begin{bmatrix} \frac{6}{4} \\ \frac{6}{4} \end{bmatrix} = \begin{bmatrix} 1,5 \\ 1,5 \end{bmatrix}$$

Macierz odchylenia (pomocnicza)

$$(\underline{x}^A - \underline{\mu}^A) = \left(\begin{bmatrix} 1 & 2 & 0 & 3 \\ 1 & 2 & 3 & 0 \end{bmatrix} - \begin{bmatrix} 1,5 & 1,5 & 1,5 & 1,5 \\ 1,5 & 1,5 & 1,5 & 1,5 \end{bmatrix} \right) = \begin{bmatrix} -0,5 & 0,5 & -1,5 & 1,5 \\ -0,5 & 0,5 & 1,5 & -1,5 \end{bmatrix}$$

Macierz kowariancji

$$\begin{aligned} C^A &= \frac{1}{4} * (\underline{x}^A - \underline{\mu}^A) * (\underline{x}^A - \underline{\mu}^A)^T = \frac{1}{4} * \begin{bmatrix} -0,5 & 0,5 & -1,5 & 1,5 \\ -0,5 & 0,5 & 1,5 & -1,5 \end{bmatrix} * \begin{bmatrix} -0,5 & -0,5 \\ 0,5 & 0,5 \\ -1,5 & 1,5 \\ 1,5 & -1,5 \end{bmatrix} = \\ &= \frac{1}{4} * \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix} = \begin{bmatrix} 1,25 & -1 \\ -1 & 1,25 \end{bmatrix} \end{aligned}$$

Selekcja cech:

$$\begin{aligned} F &= \frac{|\mu^A - \mu^B|}{\delta^A + \delta^B} \\ F_1 &= \frac{|\mu_1^A - \mu_1^B|}{\delta_1^A + \delta_1^B} = \frac{|1,5 - (-2)|}{\sqrt{1,25} + \sqrt{3}} \approx 1,228 \\ F_2 &= \frac{|\mu_2^A - \mu_2^B|}{\delta_2^A + \delta_2^B} = \frac{|1,5 - (-2)|}{\sqrt{1,25} + \sqrt{1}} \approx 1,652 \end{aligned}$$

Z punktu widzenia możliwości poprawnej klasyfikacji próbek lepszą cechą jest cecha 2 ponieważ $F_2 > F_1$

$$\begin{aligned} d(x, \{\mu_2^A, \delta_2^A\}) &= \frac{|x - \mu_2^A|}{\delta_2^A} = \frac{|0 - 1,5|}{\sqrt{1,25}} \approx 1,342 \\ d(x, \{\mu_2^B, \delta_2^B\}) &= \frac{|x - \mu_2^B|}{\delta_2^B} = \frac{|0 - (-2)|}{\sqrt{1}} = 2 \end{aligned}$$

Z obliczonych odległości na podstawie najlepszej cechy wynika, że próbka \underline{x} należy do klasy A.

Klasa A:

$$\underline{x}^A = \begin{bmatrix} 2 & 4 & 6 & 4 \\ 1 & 0 & 1 & 2 \end{bmatrix}$$

$$\underline{\mu}^A = \frac{1}{4} * \begin{bmatrix} 2+4+6+4 \\ 1+0+1+2 \end{bmatrix} = \begin{bmatrix} \frac{2+4+6+4}{4} \\ \frac{1+0+1+2}{4} \end{bmatrix} = \begin{bmatrix} \frac{16}{4} \\ \frac{4}{4} \end{bmatrix} = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$$

Macierz odchylenia (pomocnicza):

$$(\underline{x}^A - \underline{\mu}^A) = \left(\begin{bmatrix} 2 & 4 & 6 & 4 \\ 1 & 0 & 1 & 2 \end{bmatrix} - \begin{bmatrix} 4 & 4 & 4 & 4 \\ 1 & 1 & 1 & 1 \end{bmatrix} \right) = \begin{bmatrix} -2 & 0 & 2 & 0 \\ 0 & -1 & 0 & 1 \end{bmatrix}$$

Macierz kowariancji:

$$\mathbf{C}^A = \frac{1}{4} (\underline{x}^A - \underline{\mu}^A) (\underline{x}^A - \underline{\mu}^A)^T = \frac{1}{4} * \begin{bmatrix} -2 & 0 & 2 & 0 \\ 0 & -1 & 0 & 1 \end{bmatrix} * \begin{bmatrix} -2 & 0 \\ 0 & -1 \\ 2 & 0 \\ 0 & 1 \end{bmatrix} = \frac{1}{4} * \begin{bmatrix} 8 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 0,5 \end{bmatrix}$$

Klasa B:

$$\underline{\mu}^B = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad \mathbf{C}^B = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

Selekcja cech (współczynnik Fishera liniowej dyskryminacji):

$$F_1 = \frac{|\mu_1^A - \mu_1^B|}{\delta_1^A + \delta_1^B} = \frac{|4 - 0|}{\sqrt{2} + \sqrt{2}} = \sqrt{2} \approx 1,414$$

$$F_2 = \frac{|\mu_2^A - \mu_2^B|}{\delta_2^A + \delta_2^B} = \frac{|1 - 0|}{\sqrt{0,5} + \sqrt{2}} = \frac{\sqrt{2}}{3} \approx 0,471$$

Z punktu widzenia możliwość poprawnej klasyfikacji próbek lepszą cechą jest cecha 1 ponieważ $F_1 > F_2$

Odległość Mahalanobisa dla wybranej cechy (punkt do klasyfikacji $\underline{x} = \begin{bmatrix} 4 \\ 4 \end{bmatrix}$):

$$d(x_1, \{\mu_1^A, \delta_1^A\}) = \frac{|x_1 - \mu_1^A|}{\delta_1^A} = \frac{|4 - 4|}{\sqrt{2}} = 0$$

$$d(x_1, \{\mu_1^B, \delta_1^B\}) = \frac{|x_1 - \mu_1^B|}{\delta_1^B} = \frac{|4 - 0|}{\sqrt{2}} = \frac{4}{\sqrt{2}} \approx 2,828$$

Z obliczonych odległości na podstawie najlepszej cechy wynika, że próbka \underline{x} należy do klasy A.

[illegible]

KOL4

Dane są parametry statystyczne dwóch klas:

$$\underline{\mu}_A = \begin{bmatrix} 0 \\ -1 \\ -8 \end{bmatrix} \quad \underline{\mu}_B = \begin{bmatrix} 5 \\ 1 \\ -1 \end{bmatrix}$$
$$C_A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & -1 \\ 0 & -1 & 4 \end{bmatrix} \quad C_B = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

Która jednowymiarowa przestrzeń cech będzie najlepsza z punktu widzenia możliwości przeprowadzenia liniowej separacji próbek tych klas?

Współczynnik Fishera 1D

$$F_1 = \frac{|\mu_{A1} - \mu_{B1}|}{\delta_{A1} + \delta_{B1}} = \frac{|0 - 5|}{\sqrt{1} + \sqrt{2}} \approx 2,071$$
$$F_2 = \frac{|\mu_{A2} - \mu_{B2}|}{\delta_{A2} + \delta_{B2}} = \frac{|-1 - 1|}{\sqrt{2} + \sqrt{1}} \approx 0,828$$
$$F_3 = \frac{|\mu_{A3} - \mu_{B3}|}{\delta_{A3} + \delta_{B3}} = \frac{|-8 - (-1)|}{\sqrt{4} + \sqrt{2}} = \sqrt{2} \approx 2,05$$

Najlepszą cechą do dyskryminacji jest cecha 1 ponieważ $F_1 > F_3 > F_2$

Jak wyznaczyć najlepszą przestrzeń dwuwymiarową?

W celu wyznaczenia najlepszej przestrzeni dwuwymiarowej należy wyznaczyć wartość współczynnika Fishera dla każdej możliwej kombinacji par współczynników.

Współczynnik Fishera 2D

$$F_{12} = \frac{\sqrt{(\mu_{A1} - \mu_{B1})^2 + (\mu_{A2} - \mu_{B2})^2}}{\delta_{A11} + \delta_{A22} + \delta_{B11} + \delta_{B22}} = \frac{\sqrt{(0 - 5)^2 + ((-1) - 1)^2}}{1 + 2 + 2 + 1} = \frac{\sqrt{29}}{6} \approx 0,898$$
$$F_{13} = \frac{\sqrt{(\mu_{A1} - \mu_{B1})^2 + (\mu_{A3} - \mu_{B3})^2}}{\delta_{A11} + \delta_{A33} + \delta_{B11} + \delta_{B33}} = \frac{\sqrt{(0 - 5)^2 + ((-8) - (-1))^2}}{1 + 4 + 2 + 2} = \frac{\sqrt{74}}{9} \approx 0,956$$
$$F_{23} = \frac{\sqrt{(\mu_{A2} - \mu_{B2})^2 + (\mu_{A3} - \mu_{B3})^2}}{\delta_{A22} + \delta_{A33} + \delta_{B22} + \delta_{B33}} = \frac{\sqrt{((-1) - 1)^2 + ((-8) - (-1))^2}}{2 + 4 + 1 + 2} = \frac{\sqrt{53}}{9} \approx 0,808$$

Najlepszą parą cech do dyskryminacji są cechy 1 i 3 ponieważ $F_{13} > F_{12} > F_{23}$